

量化金融 / 高频交易课程报告

限价单簿中的高频做市策略复现

基于 hftbacktest 与 Hummingbot 框架

复现论文

Marco Avellaneda & Sasha Stoikov (2008)
“*High-frequency trading in a limit order book*”
Quantitative Finance, 8(3): 217–224

三轨道复现：理论蒙特卡洛 · 真实撮合引擎 · 做市机器人模型

2026 年 6 月

摘要

本报告复现做市领域的经典论文 Avellaneda & Stoikov (2008)。该文在布朗运动中价与 泊松成交到达的框架下,推导做市商按库存偏斜的保留价双边挂限价单的最优策略,并以蒙特卡洛证明:相对于”对称挂中价”的基准策略,库存策略的终端盈亏方差与库存方差显著更小。本文以三条相互印证的轨道复现该结论: **Track 0** 严格按论文 §3.3 实现蒙特卡洛,复刻其表 1-3 与图 1-4; **Track A** 将同一套 A-S 报价规则置入 `hftbacktest` 的真实订单/延迟/队列撮合引擎,并进一步在真实 **Binance** 永续合约行情(4 个交易日窗口)上运行; **Track B** 以 Hummingbot 的策略编程模型表达该策略,既给出离线复现,又在本地 **Docker** 中实际跑通其纸面交易(含将策略移植到 Hummingbot v2 API)。各轨道一致显示:库存策略将终端库存标准差稳定控制在低位,而对称基准显著漂移;真实 **Binance** 数据上库存策略的盈亏跨窗口离散度仅为对称基准的约 1/4,真实 Hummingbot 纸面交易中其库存标准差仅为对称基准的约 1/4。本文同时逐条标注各框架相对论文理想高频仿真的偏离与适用边界。

关键词: 做市; 限价单簿; 库存风险; Avellaneda-Stoikov; 高频交易; 蒙特卡洛

目录

摘要	i
1 研究背景与目标	1
2 论文模型	1
3 Track 0: 忠实复现论文蒙特卡洛	2
4 Track A: hftbacktest 真实撮合引擎	3
4.1 接入真实 Binance 行情	4
5 Track B: Hummingbot 策略模型	5
5.1 真实运行: 在 Docker 中跑通 Hummingbot 纸面交易	6
6 三轨道对照与综合结论	7
7 局限与展望	7

1 研究背景与目标

做市商 (market maker) 通过同时报出买价与卖价、赚取买卖价差为市场提供流动性，但持续成交会使其被动积累**库存**：当库存方向与随后的价格变动相反时将产生损失，此即**库存风险**。如何在 赚取价差与控制库存之间取得最优权衡，是做市的核心问题。

Avellaneda & Stoikov (2008) 给出了这一问题在随机最优控制框架下的经典近似解，其思想已成为现代电子做市与高频做市系统的理论基石。本报告的目标有三：(i) 严格复现论文的理论结果与数值实验；(ii) 将该策略迁移到**工业级高频回测引擎**与**开源做市机器人**两类真实工程框架中，检验其结论的稳健性；(iii) 诚实评估每一类框架的适用边界与定量偏离来源。

为何选择该论文。 `hftbacktest` 与 `Hummingbot` 均是围绕做市/限价单簿设计的工具：前者的旗舰示例即 GLFT/Avellaneda-Stoikov 做市，后者内置 `avellaneda_market_making` 策略模板。因此 A-S 论文是与两框架**契合度最高**的选择（相对地，需要价格内生形成的多智能体人工市场类论文与二者均不适配）。

2 论文模型

论文设中价服从算术布朗运动 $dS = \sigma dW$ 。做市商持有库存 q ，在终端时刻 T 以指数效用最大化 $\mathbb{E}[-\exp(-\gamma(X_T + q_T S_T))]$ ，其中 X_T 为现金。其近似解为两步法。第一步，由库存得到**保留价** (indifference price, 原文式 3.17)：

$$r(s, q, t) = s - q\gamma\sigma^2(T - t), \quad (1)$$

即库存为正时报价中心低于中价、以鼓励卖出。第二步，在保留价两侧挂以**最优价差**（式 3.18）：

$$\delta^a + \delta^b = \gamma\sigma^2(T - t) + \frac{2}{\gamma} \ln\left(1 + \frac{\gamma}{k}\right). \quad (2)$$

限价单被对向市价单击中的成交强度为泊松型（式 2.11）：

$$\lambda(\delta) = A e^{-k\delta}. \quad (3)$$

库存策略将报价中心置于保留价 r ；**对称基准**采用相同价差但中心置于中价 s 。论文参数为 $s = 100$, $T = 1$, $\sigma = 2$, $dt = 0.005$, $q_0 = 0$, $\gamma \in \{0.1, 0.01, 0.5\}$, $k = 1.5$, $A = 140$ ，每种设置模拟 1000 条路径。

一个关键实现细节。 论文表 1-3 报告的单一“Spread”列恰好等于式 (2) 的常数项 $(2/\gamma) \ln(1 + \gamma/k)$ （即 1.29/1.33/1.15），且其对称基准的盈亏在三个 γ 下几乎不变（约 67）。据此可判定：仿真实际挂单采用**常数价差**，时变项 $\gamma\sigma^2(T - t)$ 仅通过保留价的库存偏斜进入。本文 Track 0 采用该口径，对称基准的 γ 无关性由此自然复现，这也是本文相对若干公开复现的一处更忠实之处。

3 Track 0: 忠实复现论文蒙特卡洛

本文按论文 §3.3 的仿真流程逐式实现（src/simulate.py，以 numba 加速）。表 1-3 给出三个 γ 下”库存 vs. 对称”的盈亏均值、盈亏标准差、终端库存均值与标准差，并与原文值并列对照。

表 1 $\gamma = 0.1$ 时本文复现值与原论文值对照（1000 次蒙特卡洛模拟）

策略	盈亏均值	盈亏标准差	终端库存 q	库存标准差
库存策略（本文）	64.28	5.97	-0.100	2.93
对称基准（本文）	68.91	13.55	-0.226	8.61
库存策略（原文）	62.94	5.89	0.100	2.80
对称基准（原文）	67.21	13.43	-0.018	8.66

表 2 $\gamma = 0.01$ 时本文复现值与原论文值对照（1000 次蒙特卡洛模拟）

策略	盈亏均值	盈亏标准差	终端库存 q	库存标准差
库存策略（本文）	68.07	8.83	-0.067	5.01
对称基准（本文）	68.60	14.15	0.022	8.47
库存策略（原文）	66.78	8.76	-0.020	4.70
对称基准（原文）	67.36	13.40	-0.310	8.65

表 3 $\gamma = 0.5$ 时本文复现值与原论文值对照（1000 次蒙特卡洛模拟）

策略	盈亏均值	盈亏标准差	终端库存 q	库存标准差
库存策略（本文）	23.90	5.25	0.031	1.94
对称基准（本文）	67.29	14.67	0.654	8.92
库存策略（原文）	33.92	4.72	-0.020	1.88
对称基准（原文）	66.20	14.53	0.250	9.06

图 1 复刻论文图 1 的报价轨迹：保留价（绿）随库存在中价上下偏移，临近终端 T 时收敛于中价；买/卖报价以最优价差对称地分列两侧。图 2 复刻盈亏分布直方图，可见库存策略（实心）的分布显著窄于对称基准（空心）。




图 1 中价、保留价与最优买/卖报价 ($\gamma = 0.1$, 复刻论文图 1)。




图 2 终端盈亏分布：库存策略（实心红）方差显著小于对称基准（空心）。左 $\gamma = 0.1$ ，右 $\gamma = 0.5$ 。

结论。 $\gamma = 0.1$ 与 $\gamma = 0.01$ 的复现值与原文高度一致；三个 γ 下库存策略的盈亏标准差与库存标准差均显著小于对称基准，定性结论完整复现。 $\gamma = 0.5$ （最高风险厌恶）下库存盈亏被偏斜压得更低，是最敏感的极端情形，原因详见第 7 节。

4 Track A: hftbacktest 真实撮合引擎

本文采用 hftbacktest 2.4 的 64 字节事件格式，生成一条与 A-S 同分布的合成 L2 行情（布朗中价 + 泊松市价单消耗订单簿；见 `make_feed.py`），并将 A-S 报价规则写为 numba 的 hbt 主循环，置于其真实的订单提交、延迟、队列与撮合引擎下运行。设置两个变体：库存策略（保留价偏斜 $r = \text{mid} - c \cdot q$ ）与对称基准（ $c = 0$ ，相同半价差）。实验中的关键发现是：做市商须挂在簿内（半价差 ≥ 2 个最小变动价位）方能体现 A-S 效应——若挂在价差以内将瞬时成交并穿越零库存、反致更大方差。这是一个真实的微观结构现象。

表 4 Track A 结果 (hftbacktest, 合成 L2 行情, 时长 60 秒)

变体	终端盈亏	权益标准差	库存标准差	库存绝对峰值
库存策略	3.43	1.59	2.14	7
对称基准	23.38	9.41	10.71	25




图 3 Track A 库存路径：库存策略（红）被牢牢控制在零附近，对称基准（灰）显著漂移。

合成行情的适用边界。合成行情中普通订单流是预录制的，做市商自身成交不会反过来改变其它参与者行为；真实行情还含漂移与自相关（A-S 假设无）。故其定量值与 Track 0 不可直接比较；其价值在于在真实队列与延迟约束下验证核心结论。

4.1 接入真实 Binance 行情

为消除“行情不真实”这一局限，本文进一步用真实 **Binance USD-M 永续合约行情** 驱动同一引擎 (`download_data.py`)：从 Binance 公共归档下载 `bookTicker`（最优买卖价）与 `aggTrades`（逐笔成交），向量化解析后转为 hftbacktest 的 64 字节事件流。两处工程要点：(i) 真实价格位于交易所最小变动价位网格上，本文从数据自动反推 `tick size`（如 SOLUSDT 为 0.001），避免因档位取错而使报价塌缩；(ii) 归档时间戳为绝对纪元纳秒 ($\sim 10^{18}$)，需重甚至零点，否则引擎时钟无法到达数据区间。

仿照论文“多条路径”的做法，本文在 4 个不同交易日的 1 小时窗口（SOLUSDT，价位横跨 123-146）上分别运行库存与对称两策略 (`run_real_windows.py`)，并跨窗口聚合，结果见表 5。

表 5 Track A 真实 Binance 数据结果（SOLUSDT，4 个 1 小时窗口聚合）

变体	盈亏均值 ± 跨窗口标准差	平均库存标准差	平均权益标准差
库存策略	-31.7 ± 12.8	1.88	9.03
对称基准	-12.1 ± 55.8	17.52	21.45

论文的三项核心结论在真实数据上**全部复现**：库存标准差 1.88 vs. 17.52（低 9.3 倍）；盈亏的跨窗口离散度 ± 12.8 vs. ± 55.8 （低 4.4 倍，见图 4）；窗口内权益标准差 9.03 vs. 21.45。两策略盈亏均值皆略为负——这是紧贴盘口报价在真实行情下遭受**逆向选择**的真实结果；但库存策略以远低的风险换取了**稳定得多**的盈亏。对称基准看似”波动更大可能更赚”，实则是在用数倍的库存与盈亏方差去**豪赌方向**（库存绝对峰值常达数十手）。




图 4 Track A 真实数据：盈亏均值 ± 跨窗口标准差。对称基准的巨大误差棒（ ± 55.8 ）即其承担的方向性风险，库存策略（ ± 12.8 ）则稳定得多。

真实数据的剩余局限。 公共归档为 **BBO-only**（仅含盘口最优价，无簿内深度），故队列位置为近似；窗口为 1 小时、样本为 4 个，统计量仍有限。定量绝对值以 Track 0 为准，真实轨的价值在于在**真实微观结构**下印证”库存控制大幅降低风险”的相对结论。

5 Track B: Hummingbot 策略模型

本文将 A-S 策略表达为 Hummingbot v2 脚本(`as_market_making.py`:基于 `ScriptStrategyBase` 与 `OrderCandidate`，显式实现式 (1) 与 (2)，可直接载入真实 Hummingbot 运行)。由于完整 Hummingbot 运行时在本机安装受阻，本文提供**离线复现**(`run_hummingbot_sim.py`): 复用同一套 A-S 数学实现，但按 Hummingbot 的 `order_refresh_time` **粗刷新节奏**运行——行情仍在精细时钟上成交，而报价每若干 tick 才刷新一次、其间保持”陈旧”。

表 6 Track B 结果 (Hummingbot 秒级刷新节奏, $\gamma = 0.1$, 每 5 tick 刷新, 1000 条路径)

变体	盈亏均值	盈亏标准差	终端库存标准差
库存策略	50.22	8.19	3.12
对称基准	64.77	14.65	9.69

离线复现的适用边界。 Hummingbot 面向真实/模拟交易所、按秒级而非 tick 级运行, 缺少 tick 级队列模型, 故离线复现对论文的偏离最大; 刷新越慢, 陈旧报价的逆向成交越侵蚀盈亏 (实测每 20 tick 刷新时库存策略盈亏转负)。此外 γ 不能过大: 当偏斜量 $\gamma\sigma^2(T-t)$ 超过半价差时, 陈旧报价会被迫在远离中价处保证成交而巨亏 (实测 $\gamma = 0.5$ 即如此), 故取 $\gamma = 0.1$ 。

5.1 真实运行: 在 Docker 中跑通 Hummingbot 纸面交易

为彻底补齐”未真正运行 Hummingbot”这一局限, 本文交付并实际跑通了真实运行: `docker-compose.yml` (官方 `hummingbot/hummingbot` 镜像, 把 `as_market_making.py` 挂入容器 `scripts/`)、中文 `RUNBOOK.md`, 以及 `parse_hummingbot_logs.py` (读取 Hummingbot 的 `TradeFill` 表, 重建库存/权益序列)。

两处真实运行才暴露的工程问题(已修复)。(i) 当前官方镜像已切换到 **v2 脚本 API** (`StrategyV2Base` + `pydantic` 配置), 旧的 `ScriptStrategyBase` 已被移除——本文据此将策略移植到 **v2 API** 并在容器内验证可加载;(ii) `headless` 自启动需先初始化密码校验文件, 并通过 `conf/scripts/*.yaml` 的 `--v2` 配置启动。修复后, 策略在 `binance_paper_trade` (纸面交易, 无需 **API Key** 与**真实资金**) 上对 ETH-USDT 真实行情正常做市。

本文分别以 `inventory_skew` 开/关跑两段约 9 分钟的纸面交易, 解析其真实成交 (库存 18 笔、对称 15 笔), 结果见表 7: 真实运行同样复现核心结论——库存策略的终端库存标准差 (0.59 手) 显著小于对称基准 (2.27 手, 约 3.8 倍), 库存绝对峰值 1 vs. 5 手。

表 7 Track B 真实 Hummingbot 纸面交易结果 (ETH-USDT, 各约 9 分钟)

变体	终端盈亏	权益标准差	库存标准差 (手)	库存绝对峰值 (手)
库存策略	-0.70	0.21	0.59	1
对称基准	-1.07	0.29	2.27	5

真实运行的局限。 纸面交易样本时长仅约 9 分钟、成交十余笔, 统计量有限 (故绝对库存标准差小于其它轨道); 两策略盈亏均略为负, 系紧贴盘口的真实逆向选择与手续费所致。解析器另支持 `--make-sample` 自检 (写入独立的 `sample` 槽, 不污染真实结果)。延长运行时间即可获得更平滑的统计。

6 三轨道对照与综合结论

图 5 汇总各轨道的终端库存标准差。无论在论文的理想蒙特卡洛、hftbacktest 的真实撮合引擎（合成与真实 **Binance** 数据两版）、还是 Hummingbot 的秒级节奏下，A-S 库存策略都将库存标准差稳定控制在 2~3，而对称基准漂移至 9~18。这一致地复现了论文的核心结论：库存偏斜以少量盈亏为代价，换取数倍更低的库存与盈亏方差。尤其在真实数据上，库存标准差低至对称基准的约 1/9。




图 5 各轨道终端库存标准差对照：A-S 库存控制（红）vs. 对称基准（灰）。五组分别为论文蒙特卡洛、hftbacktest（合成/真实 **Binance**）、Hummingbot（离线/真实纸面交易），每组库存策略均显著低于对称基准。

7 局限与展望

- Track 0 的 $\gamma = 0.5$ 极端情形：**在最高风险厌恶下，离散时间步长与负半距处对成交概率的截断，使库存盈亏被压得低于原文，属模型最敏感的边界，定性结论仍成立。
- Track A 真实数据：**已接入真实 **Binance** 行情并复现核心结论；但公共归档为 BBO-only（队列近似），且样本为 4 个 1 小时窗口，统计量仍有限，可扩展至更多日 / 更长窗口。
- Track B 真实运行：**已在本地 Docker 中实际跑通 Hummingbot 纸面交易（含将策略移植到 v2 StrategyV2Base API），复现了库存控制效应；但样本仅约 9 分钟、十余笔成交，延长运行可得平滑的统计。
- 工程框架的定量偏离：**Track A/B 的绝对数值应以 Track 0 为准；其价值在于在真实约束（真实行情、队列、延迟、刷新节奏）下检验结论的稳健性。后续可以 GLFT 实用变体在线标定 A, k, σ 。

参考文献

- [1] M. Avellaneda and S. Stoikov. *High-frequency trading in a limit order book*. Quantitative Finance, 8(3):217–224, 2008.
- [2] O. Guéant, C.-A. Lehalle, and J. Fernandez-Tapia. *Dealing with the inventory risk: a solution to the market making problem*. Mathematics and Financial Economics, 7(4):477–507, 2013.
- [3] `hftbacktest` (v2.4): 高频/做市 tick 级回测引擎。 <https://github.com/nkaz001/hftbacktest>.
- [4] `Hummingbot`: 开源做市/套利交易机器人框架。 <https://github.com/hummingbot/hummingbot>.