

量化金融 / 高频交易课程报告

## 限价单簿中的高频做市策略复现

基于 hftbacktest 与 Hummingbot 框架

复现论文

*Marco Avellaneda & Sasha Stoikov (2008)*  
“*High-frequency trading in a limit order book*”  
*Quantitative Finance*, 8(3): 217–224

三轨道复现：理论蒙特卡洛 · 真实撮合引擎 · 做市机器人模型

许哲圣

2026 年 6 月 12 日

## 摘要

本报告复现做市领域的经典论文 Avellaneda & Stoikov (2008)。该文在布朗运动中价与泊松成交到达的框架下,推导做市商按库存偏斜的保留价双边挂限价单的最优策略,并以蒙特卡洛证明:相对于”对称挂中价”的基准策略,库存策略的终端盈亏方差与库存方差显著更小。本文以三条相互印证的轨道复现该结论: **Track 0** 严格按论文 §3.3 实现蒙特卡洛,复刻其表 1-3 与图 1-4; **Track A** 将同一套 A-S 报价规则置入 hftbacktest 的真实订单/延迟/队列撮合引擎,并进一步在真实 **Binance** 永续合约行情(4 个交易日窗口)上运行; **Track B** 以 Hummingbot 的策略编程模型表达该策略,既给出离线复现,又在本地 **Docker** 中实际跑通其纸面交易(含将策略移植到 Hummingbot v2 API)。各轨道一致显示:库存策略将终端库存标准差稳定控制在低位,而对称基准显著漂移;真实 **Binance** 数据上库存策略的盈亏跨窗口离散度仅为对称基准的约 1/4,真实 **Hummingbot** 纸面交易中其库存标准差仅为对称基准的约 1/4。本文同时逐条标注各框架相对论文理想高频仿真的偏离与适用边界。

**关键词:** 做市; 限价单簿; 库存风险; Avellaneda-Stoikov; 高频交易; 蒙特卡洛

## 目录

|                                                  |   |
|--------------------------------------------------|---|
| 摘要                                               | i |
| 1 研究背景与目标                                        | 1 |
| 2 论文模型                                           | 1 |
| 3 Track 0: 忠实复现论文蒙特卡洛                            | 2 |
| 4 Track A: hftbacktest 真实撮合引擎                    | 4 |
| 4.1 接入真实 Binance 行情 . . . . .                    | 4 |
| 5 Track B: Hummingbot 策略模型                       | 5 |
| 5.1 真实运行: 在 Docker 中跑通 Hummingbot 纸面交易 . . . . . | 6 |
| 6 三轨道对照与综合结论                                     | 7 |
| 7 局限与展望                                          | 7 |

## 1 研究背景与目标

做市商 (market maker) 通过同时报出买价与卖价、赚取买卖价差为市场提供流动性，但持续成交会使其被动积累**库存**：当库存方向与随后的价格变动相反时将产生损失，此即**库存风险**。如何在 赚取价差与控制库存之间取得最优权衡，是做市的核心问题。

Avellaneda & Stoikov (2008) 给出了这一问题在随机最优控制框架下的经典近似解，其思想已成为现代电子做市与高频做市系统的理论基石。本报告的目标有三：(i) 严格复现论文的理论结果与数值实验；(ii) 将该策略迁移到**工业级高频回测引擎**与**开源做市机器人**两类真实工程框架中，检验其结论的稳健性；(iii) 诚实评估每一类框架的适用边界与定量偏离来源。

本文主要工作。

1. **忠实的理论复现**：逐式实现论文 §3.3 蒙特卡洛，复刻表 1-3 与图 1-4， $\gamma = 0.1/0.01$  下各项统计量与原文高度一致；并辨析出原文仿真实际采用**常数价差**这一未明言的实现口径（见第 2 节）。
2. **hftbacktest 真实数据回测**：自行编写 Binance 公共归档下载与 64 字节事件流转换管线，在 4 个真实交易日窗口（SOLUSDT）上以真实订单/延迟/队列撮合验证结论，库存标准差较对称基准低 9.3 倍。
3. **Hummingbot 真实部署**：将策略移植到 Hummingbot v2 StrategyV2Base API，在本地 Docker 中实际跑通 `binance_paper_trade` 纸面交易（ETH-USDT 实时行情），从 TradeFill 成交日志重建库存/权益序列并复现库存控制效应。
4. **跨轨道一致性与诚实边界**：三轨道相互印证核心结论，并逐条标注各框架相对论文理想仿真的偏离来源与适用边界（第 7 节）。

为何选择该论文。hftbacktest 与 Hummingbot 均是围绕做市/限价单簿设计的工具：前者的旗舰示例即 GLFT/Avellaneda-Stoikov 做市，后者内置 `avellaneda_market_making` 策略模板。因此 A-S 论文是与两框架**契合度最高**的选择（相对地，需要价格内生形成的多智能体人工市场类论文与二者均不适配）。

## 2 论文模型

论文设中价服从算术布朗运动  $dS = \sigma dW$ 。做市商持有库存  $q$ ，在终端时刻  $T$  以指数效用最大化  $\mathbb{E}[-\exp(-\gamma(X_T + q_T S_T))]$ ，其中  $X_T$  为现金。其近似解为两步法。第一步，由库存得到**保留价** (indifference price, 原文式 3.17)：

$$r(s, q, t) = s - q\gamma\sigma^2(T - t), \quad (1)$$

即库存为正时报价中心低于中价、以鼓励卖出。第二步，在保留价两侧挂以**最优价差**（式 3.18）：

$$\delta^a + \delta^b = \gamma\sigma^2(T - t) + \frac{2}{\gamma} \ln\left(1 + \frac{\gamma}{k}\right). \quad (2)$$

限价单被对向市价单击中的成交强度为泊松型（式 2.11）：

$$\lambda(\delta) = A e^{-k\delta}. \quad (3)$$

**库存策略**将报价中心置于保留价  $r$ ；**对称基准**采用相同价差但中心置于中价  $s$ 。论文参数为  $s = 100$ ,  $T = 1$ ,  $\sigma = 2$ ,  $dt = 0.005$ ,  $q_0 = 0$ ,  $\gamma \in \{0.1, 0.01, 0.5\}$ ,  $k = 1.5$ ,  $A = 140$ ，每种设置模拟 1000 条路径。

**一个关键实现细节。** 论文表 1–3 报告的单一“Spread”列恰好等于式 (2) 的常数项  $(2/\gamma) \ln(1 + \gamma/k)$ （即 1.29/1.33/1.15），且其对称基准的盈亏在三个  $\gamma$  下几乎不变（约 67）。据此可判定：仿真实际挂单采用**常数价差**，时变项  $\gamma\sigma^2(T-t)$  仅通过保留价的库存偏斜进入。本文 Track 0 采用该口径，对称基准的  $\gamma$  无关性由此自然复现，这也是本文相对若干公开复现的一处更忠实之处。

### 3 Track 0: 忠实复现论文蒙特卡洛

本文按论文 §3.3 的仿真流程逐式实现（src/simulate.py，以 numba 加速）。表 1–3 给出三个  $\gamma$  下”库存 vs. 对称”的盈亏均值、盈亏标准差、终端库存均值与标准差，并与原文值并列对照。

表 1  $\gamma = 0.1$  时本文复现值与原论文值对照（1000 次蒙特卡洛模拟）

| 策略       | 盈亏均值  | 盈亏标准差 | 终端库存 $q$ | 库存标准差 |
|----------|-------|-------|----------|-------|
| 库存策略（本文） | 64.28 | 5.97  | -0.100   | 2.93  |
| 对称基准（本文） | 68.91 | 13.55 | -0.226   | 8.61  |
| 库存策略（原文） | 62.94 | 5.89  | 0.100    | 2.80  |
| 对称基准（原文） | 67.21 | 13.43 | -0.018   | 8.66  |

表 2  $\gamma = 0.01$  时本文复现值与原论文值对照（1000 次蒙特卡洛模拟）

| 策略       | 盈亏均值  | 盈亏标准差 | 终端库存 $q$ | 库存标准差 |
|----------|-------|-------|----------|-------|
| 库存策略（本文） | 68.07 | 8.83  | -0.067   | 5.01  |
| 对称基准（本文） | 68.60 | 14.15 | 0.022    | 8.47  |
| 库存策略（原文） | 66.78 | 8.76  | -0.020   | 4.70  |
| 对称基准（原文） | 67.36 | 13.40 | -0.310   | 8.65  |

图 1 复刻论文图 1 的报价轨迹：保留价（绿）随库存在中价上下偏移，临近终端  $T$  时收敛于中价；买/卖报价以最优价差对称地分列两侧。图 2 复刻盈亏分布直方图，可见库存策略（实心）的分布显著窄于对称基准（空心）。

表 3  $\gamma = 0.5$  时本文复现值与原论文值对照（1000 次蒙特卡洛模拟）

| 策略       | 盈亏均值  | 盈亏标准差 | 终端库存 $q$ | 库存标准差 |
|----------|-------|-------|----------|-------|
| 库存策略（本文） | 23.90 | 5.25  | 0.031    | 1.94  |
| 对称基准（本文） | 67.29 | 14.67 | 0.654    | 8.92  |
| 库存策略（原文） | 33.92 | 4.72  | -0.020   | 1.88  |
| 对称基准（原文） | 66.20 | 14.53 | 0.250    | 9.06  |




图 1 中价、保留价与最优买/卖报价 ( $\gamma = 0.1$ ，复刻论文图 1)。




图 2 终端盈亏分布：库存策略（实心红）方差显著小于对称基准（空心）。左  $\gamma = 0.1$ ，右  $\gamma = 0.5$ 。

结论。  $\gamma = 0.1$  与  $\gamma = 0.01$  的复现值与原文高度一致；三个  $\gamma$  下库存策略的盈亏标准差与库存标准差均显著小于对称基准，定性结论完整复现。 $\gamma = 0.5$ （最高风险厌恶）下库存盈亏被偏斜压得更低，是最敏感的极端情形，原因详见第 7 节。

## 4 Track A: hftbacktest 真实撮合引擎

本文采用 `hftbacktest` 2.4 的 64 字节事件格式，生成一条与 A-S 同分布的合成 L2 行情（布朗中价 + 泊松市价单消耗订单簿；见 `make_feed.py`），并将 A-S 报价规则写为 `numba` 的 `hbt` 主循环，置于其真实的订单提交、延迟、队列与撮合引擎下运行。设置两个变体：库存策略（保留价偏斜  $r = \text{mid} - c \cdot q$ ）与对称基准（ $c = 0$ ，相同半价差）。实验中的关键发现是：做市商须挂在簿内（半价差  $\geq 2$  个最小变动价位）方能体现 A-S 效应——若挂在价差以内将瞬时成交并穿越零库存、反致更大方差。这是一个真实的微观结构现象。

表 4 Track A 结果（`hftbacktest`，合成 L2 行情，时长 60 秒）

| 变体   | 终端盈亏  | 权益标准差 | 库存标准差 | 库存绝对峰值 |
|------|-------|-------|-------|--------|
| 库存策略 | 3.43  | 1.59  | 2.14  | 7      |
| 对称基准 | 23.38 | 9.41  | 10.71 | 25     |




图 3 Track A 库存路径：库存策略（红）被牢牢控制在零附近，对称基准（灰）显著漂移。

**合成行情的适用边界。** 合成行情中普通订单流是预录制的，做市商自身成交不会反过来改变其它参与者行为；真实行情还含漂移与自相关（A-S 假设无）。故其定量值与 Track 0 不可直接比较；其价值在于在真实队列与延迟约束下验证核心结论。

### 4.1 接入真实 Binance 行情

为消除“行情不真实”这一局限，本文进一步用真实 **Binance USDT 本位永续合约行情** 驱动同一引擎（`download_data.py`）：从 Binance 公共归档下载 `bookTicker`（最优买卖价）与 `aggTrades`（逐笔成交），向量化解析后转为 `hftbacktest` 的 64 字节事件流。两处工程要点：(i) 真实价格位于交易所最小变动价位网格上，本文从数据自动反推 **tick size**（如 SOLUSDT 为 0.001），避免因档位取错而使报价塌缩；(ii) 归档时间戳为绝对纪元纳秒（ $\sim 10^{18}$ ），需重基至零点，否则引擎时钟无法到达数据区间。

仿照论文”多条路径”的做法，本文在 4 个不同交易日的 1 小时窗口（SOLUSDT，价位横跨 123–146）上分别运行库存与对称两策略（run\_real\_windows.py），并跨窗口聚合，结果见表 5。

表 5 Track A 真实 Binance 数据结果（SOLUSDT，4 个 1 小时窗口聚合）

| 变体   | 盈亏均值 ± 跨窗口标准差 | 平均库存标准差 | 平均权益标准差 |
|------|---------------|---------|---------|
| 库存策略 | −31.7 ± 12.8  | 1.88    | 9.03    |
| 对称基准 | −12.1 ± 55.8  | 17.52   | 21.45   |

论文的三项核心结论在真实数据上**全部复现**：库存标准差 1.88 vs. 17.52（低 9.3 倍）；盈亏的跨窗口离散度  $\pm 12.8$  vs.  $\pm 55.8$ （低 4.4 倍，见图 4）；窗口内权益标准差 9.03 vs. 21.45。两策略盈亏均值皆略为负——这是紧贴盘口报价在真实行情下遭受**逆向选择**的真实结果；但库存策略以远低的风险换取了**稳定得多**的盈亏。对称基准看似”波动更大可能更赚”，实则是在用数倍的库存与盈亏方差去**豪赌方向**（库存绝对峰值常达数十手）。




图 4 Track A 真实数据：盈亏均值 ± 跨窗口标准差。对称基准的巨大误差棒（ $\pm 55.8$ ）即其承担的方向性风险，库存策略（ $\pm 12.8$ ）则稳定得多。

**真实数据的剩余局限。** 公共归档为 **BBO-only**（仅含盘口最优价，无簿内深度），故队列位置为近似；窗口为 1 小时、样本为 4 个，统计量仍有限。定量绝对值以 Track 0 为准，真实轨的价值在于在**真实微观结构**下印证”库存控制大幅降低风险”的相对结论。

### 5 Track B: Hummingbot 策略模型

本文将 A–S 策略表达为 Hummingbot v2 脚本(as\_market\_making.py:基于 ScriptStrategyBase 与 OrderCandidate，显式实现式 (1) 与 (2)，可直接载入真实 Hummingbot 运行)。由于完整 Hummingbot 运行时在本机安装受阻，本文提供**离线复现**(run\_hummingbot\_sim.py): 复用同一套 A–S 数学实现，但按 Hummingbot 的 order\_refresh\_time 粗刷新节奏运行——行情仍



在精细时钟上成交，而报价每若干 tick 才刷新一次、其间保持”陈旧”。

表 6 Track B 结果 (Hummingbot 秒级刷新节奏,  $\gamma = 0.1$ , 每 5 tick 刷新, 1000 条路径)

| 变体   | 盈亏均值  | 盈亏标准差 | 终端库存标准差 |
|------|-------|-------|---------|
| 库存策略 | 50.22 | 8.19  | 3.12    |
| 对称基准 | 64.77 | 14.65 | 9.69    |

离线复现的适用边界。 Hummingbot 面向真实/模拟交易所、按秒级而非 tick 级运行，缺少 tick 级队列模型，故离线复现对论文的偏离最大；刷新越慢，陈旧报价的逆向成交越侵蚀盈亏（实测每 20 tick 刷新时库存策略盈亏转负）。此外  $\gamma$  不能过大：当偏斜量  $\gamma\sigma^2(T-t)$  超过半价差时，陈旧报价会被迫在远离中价处保证成交而巨亏（实测  $\gamma = 0.5$  即如此），故取  $\gamma = 0.1$ 。

### 5.1 真实运行：在 Docker 中跑通 Hummingbot 纸面交易

为彻底补齐”未真正运行 Hummingbot”这一局限，本文交付并实际跑通了真实运行:docker-compose.yml（官方 hummingbot/hummingbot 镜像，把 as\_market\_making.py 挂入容器 scripts/）、中文 RUNBOOK.md，以及 parse\_hummingbot\_logs.py（读取 Hummingbot 的 TradeFill 表，重建库存/权益序列）。

两处真实运行才暴露的工程问题(已修复)。(i) 当前官方镜像已切换到 v2 脚本 API (StrategyV2Base + pydantic 配置)，旧的 ScriptStrategyBase 已被移除——本文据此将策略移植到 v2 API 并在容器内验证可加载；(ii) headless 自启动需先初始化密码校验文件，并通过 conf/scripts/\*.yaml 的 --v2 配置启动。修复后，策略在 binance\_paper\_trade（纸面交易，无需 API Key 与真实资金）上对 ETH-USDT 真实行情正常做市。

本文分别以 inventory\_skew 开/关跑两段约 9 分钟的纸面交易，解析其真实成交（库存 18 笔、对称 15 笔），结果见表 7：真实运行同样复现核心结论——库存策略的终端库存标准差（0.59 手）显著小于对称基准（2.27 手，约 3.8 倍），库存绝对峰值 1 vs. 5 手。


表 7 Track B 真实 Hummingbot 纸面交易结果 (ETH-USDT, 各约 9 分钟)

| 变体   | 终端盈亏  | 权益标准差 | 库存标准差 (手) | 库存绝对峰值 (手) |
|------|-------|-------|-----------|------------|
| 库存策略 | -0.70 | 0.21  | 0.59      | 1          |
| 对称基准 | -1.07 | 0.29  | 2.27      | 5          |

真实运行的局限。 纸面交易样本时长仅约 9 分钟、成交十余笔，统计量有限（故绝对库存标准差小于其它轨道）；两策略盈亏均略为负，系紧贴盘口的真实逆向选择与手续费所致。解析器另支持 --make-sample 自检（写入独立的 sample 槽，不污染真实结果）。延长运行时间即可获得更平滑的统计。

## 6 三轨道对照与综合结论

图 5 汇总各轨道的终端库存标准差。无论在论文的理想蒙特卡洛、hftbacktest 的真实撮合引擎（合成与真实 **Binance** 数据两版）、还是 Hummingbot 的秒级节奏下，A-S 库存策略都将库存标准差稳定控制在 2~3，而对称基准漂移至 9~18。这一致地复现了论文的核心结论：库存偏斜以少量盈亏为代价，换取数倍更低的库存与盈亏方差。尤其在真实数据上，库存标准差低至对称基准的约 1/9。



**图 5** 各轨道终端库存标准差对照：A-S 库存控制（红）vs. 对称基准（灰）。五组分别为论文蒙特卡洛、hftbacktest（合成/真实 **Binance**）、Hummingbot（离线/真实纸面交易），每组库存策略均显著低于对称基准。

## 7 局限与展望

- Track 0 的  $\gamma = 0.5$  极端情形：**在最高风险厌恶下，离散时间步长与负半距处对成交概率的截断，使库存盈亏被压得低于原文，属模型最敏感的边界，定性结论仍成立。
- Track A 真实数据：**已接入真实 **Binance** 行情并复现核心结论；但公共归档为 BBO-only（队列近似），且样本为 4 个 1 小时窗口，统计量仍有限，可扩展至更多日 / 更长窗口。
- Track B 真实运行：**已在本地 Docker 中实际跑通 Hummingbot 纸面交易（含将策略移植到 v2 StrategyV2Base API），复现了库存控制效应；但样本仅约 9 分钟、十余笔成交，延长运行可得平滑的统计。
- 工程框架的定量偏离：**Track A/B 的绝对数值应以 Track 0 为准；其价值在于在真实约束（真实行情、队列、延迟、刷新节奏）下检验结论的稳健性。后续可以 GLFT 实用变体在线标定  $A, k, \sigma$ 。

## 参考文献

- [1] M. Avellaneda and S. Stoikov. *High-frequency trading in a limit order book*. Quantitative Finance, 8(3):217–224, 2008.
- [2] O. Guéant, C.-A. Lehalle, and J. Fernandez-Tapia. *Dealing with the inventory risk: a solution to the market making problem*. Mathematics and Financial Economics, 7(4):477–507, 2013.
- [3] `hftbacktest` (v2.4): 高频/做市 tick 级回测引擎。 <https://github.com/nkaz001/hftbacktest>.
- [4] `Hummingbot`: 开源做市/套利交易机器人框架。 <https://github.com/hummingbot/hummingbot>.